Estado del Arte e Integración Tecnológica para Copilotos de Atención al Cliente Basados en Inteligencia Artificial Human-in-the-Loop

Marco Conceptual del Copiloto Inteligente (Human-in-the-Loop)

La evolución de los centros de interacción con clientes (*contact centers*) se encuentra marcada por el paso de sistemas automatizados rígidos a arquitecturas de asistencia inteligente centradas en el ser humano (*Human-in-the-Loop AI* o HITL)[1]. A diferencia de los chatbots autónomos de primera generación, orientados a la sustitución directa del personal y propensos a bucles de fallo ante consultas no estructuradas o ambiguas, un copiloto o sistema de asistencia al agente (*Agent Assist System*) actúa como una capa analítica y operativa en tiempo real[1]. Esta arquitectura procesa la conversación bidireccional entre el cliente y el operador, recupera el contexto relevante de la documentación corporativa y sugiere respuestas, acciones y flujos de trabajo validados antes de su emisión[1].

El sustento empírico de la asistencia HITL en entornos de producción ha sido documentado exhaustivamente. Estudios rigurosos a escala empresarial sobre el despliegue de asistentes conversacionales basados en modelos de lenguaje de gran escala (*Large Language Models*, LLMs) reportan incrementos de productividad promedio del 14% al 15% en la resolución de casos por hora[1]. Dichos incrementos no se distribuyen de forma homogénea; el impacto es asimétrico y beneficia principalmente a los trabajadores novatos o de menor calificación, quienes registran mejoras de hasta un 35% en su velocidad y tasa de resolución exitosa[1]. El copiloto opera como un acelerador de la curva de aprendizaje, permitiendo que agentes con dos meses de antigüedad alcancen el nivel de desempeño de trabajadores con más de seis meses de experiencia[1].

Dimensión Operativa	Chatbot Autónomo (Sin Supervisión)	Copiloto Inteligente (Human-in-the-Loop)
Rol del Operador	Excluido / Reemplazado	Supervisor crítico y tomador de decisiones final[1]
Manejo de Excepciones	Rígido; redirección a colas	Fluido; adaptación y edición

	de espera o bucles de error	de la sugerencia en tiempo real[1]
Riesgo de Alucinación	Exposición directa e ininterrumpida al cliente	Mitigado por el filtro de verificación humana[1]
Transferencia de Conocimiento	Estática (actualización manual de reglas)	Dinámica; captura e implicitación del conocimiento tácito[1]
Complejidad Soportada	Transacciones de baja complejidad	Problemas multitarea, normativos y multisistema[3]

Revisión Sistemática del Estado del Arte por Ejes Temáticos

Generación Aumentada por Recuperación Avanzada (Advanced, Agentic, GraphRAG, Self-RAG, CRAG, Adaptive-RAG, Reflection)

La integración de conocimiento empresarial en los LLMs exige superar la estaticidad de la memoria paramétrica y mitigar las alucinaciones factuales[4]. El paradigma fundamental de Generación Aumentada por Recuperación (*Retrieval-Augmented Generation*, RAG) combina un modelo paramétrico seq2seq con un módulo de recuperación no paramétrico sobre un corpus documental[6]. No obstante, la arquitectura inicial (*Naive RAG*) presenta limitaciones severas frente a documentos corporativos densos, ruido en la recuperación y consultas multietapa (*multi-hop*)[3].

Para resolver estos inconvenientes, la literatura reciente ha desarrollado variantes avanzadas:

- **Advanced RAG:** Introduce fases de pre-recuperación (reescritura de consultas, fragmentación jerárquica) y post-recuperación (*reranking* y compresión de contexto), optimizando la precisión de los pasajes entregados al prompt[5].
- **GraphRAG:** Emplea Grafos de Conocimiento (*Knowledge Graphs*) construidos mediante LLMs para extraer entidades y relaciones relacionales[10]. Mediante algoritmos de detección de comunidades como Leiden, genera resúmenes jerárquicos que permiten responder a consultas de síntesis global sobre la totalidad del corpus empresarial, donde la búsqueda vectorial tradicional por similitud de coseno fracasa[3].
- **Self-RAG:** Introduce un mecanismo de entrenamiento con tokens de reflexión ([IsRel], [IsSup], [IsUse]) que le permite al modelo autorregular dinámicamente cuándo consultar el retriever, evaluar la relevancia de los documentos y verificar si la generación está respaldada por el contexto recuperado.
- **Corrective RAG (CRAG):** Implementa un evaluador de recuperación ligero que determina el nivel de confianza de los documentos recuperados. En escenarios de alta

confianza, refina los fragmentos; en casos de ambigüedad o baja confianza, activa búsquedas externas en la web o fuentes alternativas, filtrando activamente el ruido documental.
- **Adaptive-RAG:** Clasifica la complejidad de la consulta de entrada mediante un modelo discriminador, enrutando automáticamente la solicitud hacia respuestas basadas en memoria paramétrica, RAG de un solo paso o itinerarios de recuperación multietapa según la exigencia del problema.
- **Reflection RAG / Agentic RAG:** Combina la recuperación de información con bucles de razonamiento y acción (*Reason + Act*), permitiendo que el copiloto formule hipótesis, ejecute múltiples búsquedas iterativas y evalúe la suficiencia de la evidencia antes de estructurar la propuesta final para el operador[13].

Recuperación e Indexación Empresarial (Dense, Sparse, Híbrido, Embeddings y Rerankers)

La efectividad del módulo de recuperación en entornos corporativos requiere equilibrar la precisión semántica con la coincidencia exacta de términos técnicos, códigos de producto o políticas específicas[10]. La literatura demuestra que el enfoque óptimo reside en las arquitecturas de Búsqueda Híbrida (*Hybrid Search*)[10]:

- **Sparse Retrieval (Búsqueda Léxica Avanzada):** Evolucionando más allá del algoritmo tradicional BM25, modelos neurales dispersos como **SPLADE** (*Sparse Lexical and Expansion Model*) utilizan las capas de atención de transformers para expandir la consulta con términos del vocabulario de forma ponderada, preservando la compatibilidad con índices invertidos tradicionales y garantizando precisión exacta[10].
- **Dense Retrieval (Búsqueda Semántica):** Transforma textos en representaciones vectoriales densas mediante encoders especializados. Los modelos de la familia **BGE** (*BAAI General Embedding*), **E5** (*Embrace The Unreasonable Effectiveness of Text Embeddings*) y **Jina Embeddings** representan el estado del arte en captura de relaciones conceptuales abstractas y soporte multilingüe.
- **Late Interaction (ColBERT):** Preserva los vectores por token de la consulta y el documento en lugar de comprimirlos en una sola representación vectorial. A través del operador MaxSim, ColBERT evalúa la interacción entre tokens con latencias de milisegundos, aproximándose a la precisión de los modelos Cross-Encoder.
- **Re-ranking (Cross-Encoders):** Como etapa de refinamiento posterior a la recuperación primaria, los modelos Cross-Encoder (ej. **Cohere Rerank** o variantes ajustadas de **BERT/RoBERTa**) procesan conjuntamente el par consulta-pasaje dentro de las capas de atención del transformer, reordenando los N candidatos superiores y mejorando métricas de ranking como MRR@10 y NDCG@10[15].

Agentes de IA, Memoria Conversacional y Protocolo MCP

El escalado funcional de un copiloto desde la generación de texto hasta la asistencia operativa requiere capacidades agenticas[8]. La llamada a funciones (*Function Calling*) y el uso de herramientas (*Tool Use*) permiten al LLM estructurar comandos en JSON para interactuar con

bases de datos, sistemas CRM y plataformas de facturación[3].
En arquitecturas donde los agentes deben aprender de fallos interactivos, marcos como **Reflexion** reemplazan la actualización de pesos por retroalimentación lingüística guardada en un búfer de memoria episódica[13]. Esto permite al copiloto evaluar respuestas erróneas de APIs o búsquedas fallidas y corregir sus parámetros de llamada de forma autónoma[13].
Asimismo, la variabilidad de interfaces propietarias en el desarrollo de agentes ha impulsado la adopción del **Model Context Protocol (MCP)** desarrollado por Anthropic. MCP establece una especificación cliente-servidor abierta sobre JSON-RPC 2.0 que estandariza tres primitivas contextuales:

- **Resources (Recursos):** Datos de solo lectura expuestos mediante URIs (ej. historiales de casos, fichas de cliente) que el copiloto adjunta dinámicamente.
- **Prompts:** Plantillas de instrucciones y flujos de trabajo preconfigurados.
- **Tools (Herramientas):** Funciones ejecutables respaldadas por esquemas estritos de validación que permiten al copiloto modificar el estado del sistema (ej. procesar devoluciones o rearmar servicios) tras la aprobación del operador.

Para mantener la coherencia en conversaciones de soporte prolongadas, el copiloto debe integrar arquitecturas de memoria multinivel (memoria de trabajo en el prompt actual, memoria episódica de la interacción reciente y memoria semántica sobre el perfil del usuario), superando el problema de la pérdida de atencionalidad (*Needle in a Haystack*) común en contextos extensos sin filtrado.

Factualidad, Mitigación de Alucinaciones y Benchmarks de Evaluación

La veracidad de las recomendaciones entregadas al operador humano es condicionante para la adopción en producción[4]. Las técnicas de reducción de alucinaciones incluyen la generación explícita de citas acopladas al contexto[9] y la verificación mediante Inferencia de Lenguaje Natural (*Natural Language Inference*, NLI)[20].
Para la evaluación continua de estas capacidades sin recurrir a costosas anotaciones humanas manuales, la industria ha estandarizado la metodología *LLM-as-a-Judge*:

- **RAGAS (Retrieval Augmented Generation Assessment):** Marco de evaluación de referencia que descompone el desempeño del RAG en métricas cuantitativas: *Faithfulness* (proporción de la respuesta respaldada lógicamente por el contexto), *Answer Relevancy* (coincidencia de la respuesta con la intención de la consulta), *Context Precision* (densidad de información útil en los primeros fragmentos recuperados) y *Context Recall* (recuperación completa de la información requerida)[3].
- **AgentBench:** Entorno de evaluación benchmark diseñado para medir la capacidad de los LLMs actuando como agentes en la resolución de tareas complejas en entornos secuenciales y de uso de herramientas[8].
- **LongBench & CRAG Benchmark:** Suites orientadas a evaluar el razonamiento sobre contextos extremadamente largos y la capacidad de resistencia del sistema frente a información distorsionada o irrelevante.

Análisis Comparativo de Soluciones Comerciales e

Industriales

El ecosistema empresarial ofrece diversas soluciones de software para centros de contacto e interacción con clientes (*CCaaS*) e inteligencias artificiales corporativas. La siguiente tabla sintetiza las características técnicas de las principales plataformas comerciales:

Plataforma Comercial	**Arquitectura y Motor RAG**	**Mecanismo Human-in-the-Loop**	**Interoperabilidad / Tool Use**	**Enfoque Principal**
Microsoft Copilot Studio / Dynamics 365 Copilot	RAG sobre Azure AI Search con Búsqueda Híbrida y Reranker Semántico	Panel lateral omnicanal; el operador edita y aprueba respuestas antes de enviar	Conectores Power Platform, APIs REST y protocolo MCP empresarial	Asistencia integral al operador en CRM y soporte corporativo
Google Agent Assist / Vertex AI Search	Vertex AI Search con indexación denso-dispersa y grafos contextuales	Transcripción en tiempo real y sugerencia proactiva de artículos y respuestas	Integración nativa con Google Cloud Pub/Sub, Apigee y Vertex Extensions	Centros de contacto de gran escala y telefonía conversacional
Salesforce Agentforce / Einstein	RAG dinámico sobre Data Cloud con grafos de metadatos del cliente	Interfaz integrada en Service Cloud; autorización explícita para acciones	Flow Builders, Apex Actions y llamadas a servicios web externos	Automatización y copiloto integrado en ecosistema Salesforce
Zendesk AI	RAG sobre bases de conocimiento corporativas e historial de tickets	Sugerencias de respuesta a un clic en el espacio de trabajo del agente	Apps Marketplace APIs y automatizaciones basadas en intenciones	Gestión de tickets de soporte y atención al cliente omnicanal
Intercom Fin	RAG con filtrado	Asistencia en modo	Webhooks, conectores	Empresas de software SaaS

AI	estricto de seguridad sobre repositorios help-center	sugerencia para operadores o automatización parcial	Zapier y llamadas a servicios REST	y soporte al cliente digital
Amazon Q Business / Amazon Connect Wisdom	RAG sobre Amazon Kendra y OpenSearch Service con conectores nativos	Módulo Agent Assist con entrega proactiva de respuestas durante la llamada	AWS Lambda Functions e integración con servicios de AWS	Centros de contacto basados en infraestructura AWS
IBM watsonx Assistant	RAG sobre watsonx.discovery con búsqueda híbrida y guardarraíles	Panel asistido con métricas de confianza e historial de fuentes	watsonx Orchestrate, conectores OpenAPI y flujos corporativos	Entornos altamente regulados (sector bancario y asegurador)
ServiceNow AI Agent	RAG integrado sobre ServiceNow Knowledge Management	Asistencia directa en la consola de trabajo del agente de soporte ITSM	IntegrationHub, flujos de automatización y llamadas a workflows	Soporte técnico interno y gestión de servicios IT

Matriz Bibliográfica Detallada del Estado del Arte

A continuación se presentan las tablas detalladas con la matriz sintética de las referencias fundamentales y representativas del estado del arte, incorporando los 23 atributos analíticos solicitados.

Matriz Bibliográfica: Investigaciones Científicas Fundamentales y Metodológicas (Parte 1)

Atributo / Campo	Referencia 1: Impacto	Referencia 2: Arquitectura RAG	Referencia 3: Recuperación en

	Operacional HITL	Base	Grafos
Título	Generative AI at Work[1]	Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[6]	From Local to Global: A Graph RAG Approach to Query-Focused Summarization[12]
Autores	E. Brynjolfsson, D. Li, L. Raymond[1]	P. Lewis, E. Perez, A. Piktus, F. Petroni et al.[6]	D. Edge, H. Trinh, N. Cheng, J. Bradley et al.[12]
Año	2025 (Working Paper 2023)[1]	2020[6]	2024[12]
Editorial / Conferencia	Quarterly Journal of Economics / NBER[1]	NeurIPS 2020[6]	arXiv / Microsoft Research[12]
Tipo	Artículo de Revista Científica[25]	Artículo de Conferencia Internacional	Preprint de Investigación Corporativa[12]
DOI	10.1093/qje/qjae041 [cite: 25, 26]	10.48550/arXiv.2005.11401 [cite: 6]	10.48550/arXiv.2404.16130 [cite: 12]
URL Oficial	https://academic.oup.com/qje/article/140/2/889/7990658 [cite: 25]	https://arxiv.org/abs/2005.11401 [cite: 6]	https://arxiv.org/abs/2404.16130 [cite: 12]
Citas Aprox.	> 1,200[9]	> 3,500[9]	> 450[9]
Nivel Importancia	Nivel 1 (Imprescindible)[1]	Nivel 1 (Imprescindible)[6]	Nivel 1 (Imprescindible)[12]
Tema Principal	Copilotos IA y productividad Human-in-the-Loop[1]	Generación Aumentada por Recuperación (RAG)[6]	RAG basado en Grafos de Conocimiento (GraphRAG)[12]

Problema que Resuelve	Evaluó si la IA mejora o degrada el trabajo real en centros de contacto[1]	Alucinaciones y falta de actualización en LLMs[5]	Incapacidad de RAG vectorial para responder preguntas globales del corpus[12]
Método Utilizado	Despliegue escalonado de copiloto IA en 5,172 agentes de soporte[2]	Combinación de retriever denso (DPR) con modelo seq2seq (BART)[9]	Extracción de grafos por LLM + clustering de comunidades Leiden[12]
Arquitectura	Interfaz asistida de sugerencia conversacional en tiempo real[1]	Dual-Encoder Retriever + Generador BART Fine-tuned[9]	Graph Construction + Community Summarization + RAG Generation[12]
Dataset	3 millones de chateos reales de soporte al cliente[1]	Natural Questions, TriviaQA, WebQuestions, FEVER[9]	Corpus de podcasts de dominio público y documentos corporativos[12]
LLM Utilizado	Modelo conversacional basado en la familia GPT[1]	BART-large[9]	GPT-4 / GPT-3.5-Turbo[12]
Retriever Utilizado	Búsqueda semántica sobre base de conocimientos interna[1]	Dense Passage Retriever (DPR)[9]	Indexador de Grafos y Búsqueda Vectorial Híbrida[12]
Embeddings	Embeddings propietarios de la plataforma[1]	Bi-Encoder BERT Embeddings[9]	OpenAI text-embedding-3-dense / Azure OpenAI[12]
Reranker	No especificado en el estudio de	No utilizado en la versión original[6]	Algoritmo de relevancia

	campo[1]		comunitaria en grafo[12]
Métricas	Resoluciones/hora (AHT), FCR, Sentiment, Retention[1]	EM (Exact Match), F1-Score, Perplexity[9]	Comprehensiveness, Empowerment, Diversity, Directness[12]
Resultados	**+14-15% productividad promedio**; **+35% novatos** [cite: 1, 2, 7]	SOTA en QA de dominio abierto sin reentrenar pesos del generador[6]	Supera a Naive RAG en exhaustividad y respuestas globales[12]
Limitaciones	Medido en una sola empresa; posible sesgo de implementación[2]	Mayor latencia por llamada al retriever en cada inferencia[5]	Elevado costo computacional en la fase de indexación del grafo[12]
Contribución Principal	Demostró empíricamente que la IA iguala habilidades y ayuda al novato[1]	Estableció el estándar metodológico para acoplar LLMs a datos[6]	Demostró que los grafos resuelven la síntesis global sobre documentos[12]
Aplicación Tesis	Base de justificación teórica y económica del copiloto HITL[1]	Fundamento del módulo RAG básico de la arquitectura del copiloto[6]	Estructuración de manuales jerárquicos complejos para el operador

Matriz Bibliográfica: Agentes, Refinaminto, Evaluación y Búsqueda (Parte 2)

Atributo / Campo	Referencia 4: Agentic Reflexion	Referencia 5: Framework RAGAS	Referencia 6: Búsqueda Dispersa SPLADE
Título	Reflexion: Language Agents with Verbal	RAGAS: Automated Evaluation of	SPLADE: Sparse Lexical and

	Reinforcement Learning[13]	Retrieval Augmented Generation[21]	Expansion Model for Information Retrieval[10]
Autores	N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, S. Yao[13]	Shahul ES, J. James, L. Espinosa-Anke, S. Schockaert[20]	T. Formal, B. Mourregot, S. Clinchant, B. Piwowarski[10]
Año	2023[13]	2024 (Preprint 2023)[9]	2021[10]
Editorial / Conferencia	NeurIPS 2023[13]	EACL 2024 (System Demos)[9]	ACM SIGIR 2021[10]
Tipo	Artículo de Conferencia Internacional[14]	Artículo de Conferencia Internacional[22]	Artículo de Conferencia Internacional[10]
DOI	10.52202/075280-0377 [cite: 13]	10.18653/v1/2024.eacl-demo.16 [cite: 22]	10.1145/3404835.3463098 [cite: 10]
URL Oficial	https://openreview.net/forum?id=vAElhFcKW6 [cite: 14]	https://aclanthology.org/2024.eacl-demo.16/ [cite: 22]	https://dl.acm.org/doi/10.1145/3404835.3463098 [cite: 10]
Citas Aprox.	> 4,200[13]	> 880[9]	> 400[9]
Nivel Importancia	Nivel 1 (Imprescindible)[13]	Nivel 1 (Imprescindible)[21]	Nivel 1 (Imprescindible)[10]
Tema Principal	Aprendizaje por refuerzo verbal y memoria de agentes[13]	Evaluación automatizada sin ground-truth de RAG[21]	Búsqueda léxica dispersa basada en modelos neuronales[10]
Problema que Resuelve	Reintento estático de agentes ante fallos en ejecución	Costo y lentitud de evaluar RAG con anotaciones	Inexactitud de búsqueda semántica pura en

	de herramientas[14]	humanas[21]	términos exactos[10]
Método Utilizado	Guardado de autocrítica en texto en un búfer de memoria episódica[14]	Evaluación mediante métricas desacopladas *LLM-as-a-Judge* [cite: 21, 22]	Expansión de términos mediante log-probabilities de BERT[10]
Arquitectura	Actor-Evaluator-Self-Reflection Loop + Memory Buffer[14]	Suite de Métricas (Faithfulness, Relevancy, Precision, Recall)[3]	Sparse Neural Retriever con representación en Inverted Index[10]
Dataset	HumanEval, MBPP, HotPotQA, ALFWorld[14]	WikiQA, MS MARCO, Datasets sintéticos RAG[9]	MS MARCO Passage Ranking, TREC-COVID[15]
LLM Utilizado	GPT-4, GPT-3.5-Turbo, PaLM 2[19]	GPT-4 (como Juez Evaluador)[20]	BERT-base-uncased[10]
Retriever Utilizado	Vector Memory backed by FAISS[13]	Módulos genéricos RAG bajo evaluación[9]	Sparse Index Lucene / Elasticsearch[10]
Embeddings	Dense embeddings para búsqueda en memoria episódica[13]	No aplica directamente (evalúa textos finales)[21]	Sparse Weight Vectors sobre el vocabulario de BERT[10]
Reranker	Reordenamiento por relevancia semántica de reflexiones[29]	No aplica[21]	No requiere reranker directo (reemplaza o alimenta BM25)[10]
Métricas	Pass@1 Accuracy, Task Completion Rate[19]	Correlation with Human Judgments, Faithfulness Score[9]	MRR@10, NDCG@10, Latency (ms)[15]
Resultados	**91% pass@1 en HumanEval** (superando el 80%	Alta correlación con evaluaciones humanas en	Supera significativamente a BM25 manteniendo

	del GPT-4 base)[19]	veracidad[3]	baja latencia[10]
Limitaciones	Aumento del consumo de tokens al acumular historial de reflexiones[27]	Sensibilidad del scoring al LLM seleccionado como juez[20]	Requiere re-indexación cuando se altera la arquitectura del encoder
Contribución Principal	Demostró que el aprendizaje en agentes puede ser puramente en contexto[13]	Estandarizó el benchmarking automatizado para sistemas RAG[21]	Combinó la velocidad del índice invertido con la semántica profunda[10]
Aplicación Tesis	Mecanismo de autocorrección en llamadas a API en el copiloto[13]	Framework de validación experimental de los resultados del copiloto[21]	Componente léxico del motor de búsqueda híbrida de la tesis[10]

Clasificación Bibliográfica Multinivel

Para el desarrollo del capítulo de Estado del Arte, las referencias analizadas han sido estructuradas en cuatro niveles en función de su peso metodológico, nivel de adopción industrial e impacto en la arquitectura propuesta para el copiloto:

- **Nivel 1 (Imprescindibles - 15 Trabajos Clave):**

1. *Generative AI at Work* (Brynjolfsson et al., 2025)[1]
2. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks* (Lewis et al., 2020)[6]
3. *From Local to Global: A Graph RAG Approach to Query-Focused Summarization* (Edge et al., 2024)[10]
4. *Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection* (Asai et al., 2024)
5. *Corrective Retrieval Augmented Generation* (Yan et al., 2024)
6. *Reflexion: Language Agents with Verbal Reinforcement Learning* (Shinn et al., 2023)[13]
7. *RAGAS: Automated Evaluation of Retrieval Augmented Generation* (Shahul ES et al., 2024)[21]
8. *AgentBench: Evaluating LLMs as Agents* (Liu et al., 2024)[8]
9. *SPLADE: Sparse Lexical and Expansion Model for Information Retrieval* (Formal et al., 2021)[10]
10. *Passage Re-ranking with BERT* (Nogueira & Cho, 2019)[15]
11. *ColBERT: Efficient and Effective Passage Search via Late Interaction* (Khattab & Zaharia,

2020)

12. *Toolformer: Language Models Can Teach Themselves to Use Tools* (Schick et al., 2023)[18]
13. *Adaptive-RAG: Learning to Adapt Retrieval-Augmented LLMs* (Jeong et al., 2024)
14. *MemGPT: Towards LLMs as Operating Systems* (Packer et al., 2023)
15. *Model Context Protocol Specification* (Anthropic, 2024)

- **Nivel 2 (Muy Importantes - 20 Trabajos Avanzados):** 16. *BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity* (Chen et al., 2024) 17. *Text Embeddings by Weakly-Supervised Contrastive Pre-training - E5* (Wang et al., 2022) 18. *Jina Embeddings 2: 8K Context English Embeddings* (Günther et al., 2023) 19. *ReAct: Synergizing Reasoning and Acting in Language Models* (Yao et al., 2023) 20. *LongBench: A Bilingual Benchmark for Long Context Understanding* (Bai et al., 2023) 21. *Context-Faithful Prompting for Large Language Models* (Zhou et al., 2023)[31] 22. *Retrieval-Augmented Generation for Large Language Models: A Survey* (Gao et al., 2023)[5] 23. *AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation* (Wu et al., 2023) 24. *MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework* (Hong et al., 2024) 25. *Augmented Language Models: a Survey* (Mialon et al., 2023) 26. *Is ChatGPT a Good Ranker? Numerical Insights on Pairwise Reranking* (Sun et al., 2023) 27. *Evaluating LLMs on Information Extraction* (Li et al., 2023)[20] 28. *The Internal State of an LLM Knows When It's Lying* (Azaria & Mitchell, 2023)[20] 29. *Self-Consistency Improves Chain of Thought Reasoning in Language Models* (Wang et al., 2023) 30. *Enterprise Search in the Era of Large Language Models* (Dahiya et al., 2024) 31. *Improving Language Models by Retrieving from Trillions of Tokens - RETRO* (Borgeaud et al., 2022)[20] 32. *REALM: Retrieval-Augmented Language Model Pre-training* (Guu et al., 2020)[9] 33. *Leveraging Passage Retrieval with Generative Language Models - FiD* (Izacard & Grave, 2021) 34. *RePlug: Retrieval-Augmented Language Modeling for Inference* (Glass et al., 2022)[9] 35. *Active Retrieval Augmented Generation - FLARE* (Jiang et al., 2023)
- **Nivel 3 (Complementarios - 18 Trabajos de Dominio y Métodos):** 36. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding* (Devlin et al., 2019)[20] 37. *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks* (Reimers & Gurevych, 2019) 38. *The Probabilistic Relevance Framework: BM25 and Beyond* (Robertson & Zaragoza, 2009) 39. *Dense Passage Retrieval for Open-Domain Question Answering* (Karpukhin et al., 2020) 40. *Attention Is All You Need* (Vaswani et al., 2017) 41. *Llama 2: Open Foundation and Fine-Tuned Chat Models* (Touvron et al., 2023) 42. *Mixtral of Experts* (Jiang et al., 2024) 43. *GPT-4 Technical Report* (OpenAI, 2023) 44. *The Claude 3 Model Family* (Anthropic, 2024) 45. *Gemini 1.5: Unlocking multimodal understanding across millions of tokens* (Google, 2024) 46. *Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text Retrieval - Ance* (Xiong et al., 2021) 47. *SimCSE: Simple Contrastive Learning of Sentence Embeddings* (Gao et al., 2021) 48. *RoFormer: Enhanced Transformer with Rotary Position Embedding* (Su et al., 2024) 49. *LongLoRA: Efficient Fine-tuning of Long-Context Large Language Models* (Chen et al., 2023) 50. *Efficient Streaming Language Models with Attention Sinks* (Xiao et al., 2023) 51. *Sirens in the Stories: Preventing Hallucinations in LLMs* (Zhang et al., 2023)[20] 52. *Survey of*

Hallucination in Natural Language Generation (Ji et al., 2023)[20] 53. *Factual Error Detection in Generation via Atomic Fact Verification - FActScore* (Min et al., 2023)

- **Nivel 4 (Opcionales y Documentación Oficial de Plataformas Comerciales - 14 Fuentes):** 54. *Microsoft Copilot Studio Documentation* (Microsoft, 2024) 55. *Dynamics 365 Contact Center & Copilot Architecture* (Microsoft, 2024) 56. *Agent Assist Architecture & Integration Guide* (Google Cloud, 2024) 57. *Vertex AI Search and Conversation Documentation* (Google Cloud, 2024) 58. *Agentforce Platform Architecture & Einstein AI* (Salesforce, 2024) 59. *Zendesk AI and Agent Workspace Technical Overview* (Zendesk, 2024) 60. *Fin AI Copilot Technical Documentation* (Intercom, 2024) 61. *Amazon Q Business & Amazon Connect Wisdom Integration* (AWS, 2024) 62. *IBM watsonx Assistant and Discovery Technical Architecture* (IBM, 2024) 63. *ServiceNow AI Agent and Now Assist Documentation* (ServiceNow, 2024) 64. *OpenAI Responses API & Realtime API Reference* (OpenAI, 2024) 65. *Claude Enterprise & Tool Use Documentation* (Anthropic, 2024) 66. *Rethinking Query Expansion for BERT Reranking* (Padaki et al., 2020)[11] 67. *Chain-of-Verification Reduces Hallucinations in Large Language Models* (Dhuliawala et al., 2023)

Repositorio Bibliográfico en Formato BibTeX (.bib)

Fragmento de código

```
@article{bryniolfsson2025generative,
  author  = {Brynjolfsson, Erik and Li, Danielle and Raymond, Lindsey R.},
  title   = {Generative AI at Work},
  journal = {The Quarterly Journal of Economics},
  volume  = {140},
  number  = {2},
  pages   = {889--942},
  year    = {2025},
  publisher = {Oxford University Press},
  doi     = {10.1093/qje/qjae041}
}

@inproceedings{lewis2020retrieval,
  author  = {Lewis, Patrick and Perez, Ethan and Piktus, Aleksandra and Petroni, Fabio and Karpukhin, Vladimir and Goyal, Naman and Kuttler, Heinrich and Lewis, Mike and Yih, Wen-tau and Rockt{\"a}schel, Tim and Riedel, Sebastian and Kiela, Douwe},
  title   = {Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks},
  booktitle = {Advances in Neural Information Processing Systems (NeurIPS)},
  volume  = {33},
```

pages = {9459--9474}
year = {2020}
}

@article{edge2024local,
author = {Edge, Darren and Trinh, Ha and Cheng, Newman and Bradley, Joshua and Chao, Alex and Mody, Apurva and Truitt, Jakob and Larson, Jonathan},
title = {From Local to Global: A Graph RAG Approach to Query-Focused Summarization},
journal = {arXiv preprint arXiv:2404.16130},
year = {2024}
}

@inproceedings{asai2024selfrag,
author = {Asai, Akari and Wu, Zeqiu and Wang, Yizhong and Sil, Avirup and Hajishirzi, Hannaneh},
title = {Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection},
booktitle = {International Conference on Learning Representations (ICLR)},
year = {2024}
}

@inproceedings{yan2024corrective,
author = {Yan, Shi-Qi and Gu, Jia-Chen and Zhu, Yunfan and Ling, Zhen-Hua},
title = {Corrective Retrieval Augmented Generation},
booktitle = {International Conference on Machine Learning (ICML)},
year = {2024}
}

@inproceedings{shinn2023reflexion,
author = {Shinn, Noah and Cassano, Federico and Gopinath, Ashwin and Narasimhan, Karthik and Yao, Shunyu},
title = {Reflexion: Language Agents with Verbal Reinforcement Learning},
booktitle = {Advances in Neural Information Processing Systems (NeurIPS)},
volume = {36},
pages = {8634--8652},
year = {2023}
}

@inproceedings{shahul2024ragas,
author = {Es, Shahul and James, Jithin and Espinosa-Anke, Luis and Schockaert, Steven},
title = {RAGAs: Automated Evaluation of Retrieval Augmented Generation},
booktitle = {Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations},

```
  pages     = {150--158},
  year      = {2024},
  publisher = {Association for Computational Linguistics},
  doi       = {10.18653/v1/2024.eacl-demo.16}
}

@inproceedings{liu2024agentbench,
  author    = {Liu, Xiao and Yu, Hao and Zhang, Hanyu and Xu, Zhenrui and Lei, Xinyi and Lai,
  Hanyu and Gu, Yu and Ding, Hang and Men, Kaiwen and Yang, Kejuan and Zhang, Shuntian
  and Deng, Xiang and Zeng, Aohan and Du, Zhengxiao and Zhang, Chenhui and Shen,
  Sheng and Zhang, Tianjun and Su, Yu and Sun, Maosong and Dong, Yuxiao and Tang, Jie},
  title     = {AgentBench: Evaluating LLMs as Agents},
  booktitle = {International Conference on Learning Representations (ICLR)},
  year      = {2024}
}

@inproceedings{formal2021splade,
  author    = {Formal, Thibault and Mourregot, Benjamin and Clinchant, St{\'e}phane and
  Piwowarski, Benjamin},
  title     = {SPLADE: Sparse Lexical and Expansion Model for Information Retrieval},
  booktitle = {Proceedings of the 44th International ACM SIGIR Conference on Research
  and Development in Information Retrieval},
  pages     = {1401--1410},
  year      = {2021},
  doi       = {10.1145/3404835.3463098}
}

@article{nogueira2019passage,
  author    = {Nogueira, Rodrigo and Cho, Kyunghyun},
  title     = {Passage Re-ranking with BERT},
  journal   = {arXiv preprint arXiv:1901.04085},
  year      = {2019}
}

@inproceedings{khattab2020colbert,
  author    = {Khattab, Omar and Zaharia, Matei},
  title     = {ColBERT: Efficient and Effective Passage Search via Contextualized Late
  Interaction over BERT},
  booktitle = {Proceedings of the 43rd International ACM SIGIR Conference on Research
  and Development in Information Retrieval},
  pages     = {39--48},
  year      = {2020},
  doi       = {10.1145/3397271.3401075}
```

```
@inproceedings{schick2023toolformer,
  author    = {Schick, Timo and Dwivedi-Yu, Jane and Dess{\`i}, Roberto and Raileanu,
Roberta and Lomeli, Maria and Zettlemoyer, Luke and Cancedda, Nicola and Scialom,
Thomas},
  title     = {Toolformer: Language Models Can Teach Themselves to Use Tools},
  booktitle = {Advances in Neural Information Processing Systems (NeurIPS)},
  volume    = {36},
  year      = {2023}
}

@inproceedings{jeong2024adaptive,
  author    = {Jeong, Sohee and Baek, Jinheon and Cho, Sukmin and Sung, Myeongjun and
Park, Jong C.},
  title     = {Adaptive-RAG: Learning to Adapt Retrieval-Augmented LLMs},
  booktitle = {Findings of the Association for Computational Linguistics: NAACL 2024},
  year      = {2024}
}

@article{packer2023memgpt,
  author    = {Packer, Charles and Fang, Vivian and Patil, Shishir G. and Lin, Kevin and
Wooders, Sarah and Gonzalez, Joseph E.},
  title     = {MemGPT: Towards LLMs as Operating Systems},
  journal   = {arXiv preprint arXiv:2310.08560},
  year      = {2023}
}

@manual{anthropic2024mcp,
  title        = {Model Context Protocol (MCP) Specification},
  author       = {{Anthropic PBC}},
  year         = {2024},
  url          = {https://modelcontextprotocol.io},
  note         = {Official Specification for Enterprise AI Tool Interoperability}
}

@techreport{chen2024bge,
  author      = {Chen, Jianlyu and Xiao, Shitao and Zhang, Peitian and Luo, Kun and Zhao,
Defu and Liu, Zheng},
  title       = {BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity at
Scale},
  institution = {Beijing Academy of Artificial Intelligence (BAAI)},
  year        = {2024}
```

note = {arXiv:2402.03216}
}

@article{wang2022e5,
author = {Wang, Liang and Yang, Nan and Huang, Xiaodi and Jiao, Binxing and Yang, Linjun and Jiang, Daxin and Majumder, Rangan and Wei, Furu},
title = {Text Embeddings by Weakly-Supervised Contrastive Pre-training},
journal = {arXiv preprint arXiv:2212.03533},
year = {2022}
}

@article{gunther2023jina,
author = {G{\"u}nther, Michael and Xiao, Han and Wang, Bo and M{\"o}ller, Timo},
title = {Jina Embeddings 2: 8K Context English Embeddings for Dense Retrieval},
journal = {arXiv preprint arXiv:2310.19923},
year = {2023}
}

@inproceedings{yao2023react,
author = {Yao, Shunyu and Zhao, Jeffrey and Yu, Dian and Du, Nan and Shafran, Izhak and Narasimhan, Karthik and Cao, Yuan},
title = {ReAct: Synergizing Reasoning and Acting in Language Models},
booktitle = {International Conference on Learning Representations (ICLR)},
year = {2023}
}

@article{bai2023longbench,
author = {Bai, Yushi and Lv, Xin and Zhang, Jiajie and Lyu, Hongchang and Tang, Jiankai and Huang, Zhilin and Zheng, Yuxiao and Liu, Xiao and Zeng, Aohan and Tam, Cheung and Tam, Shuntian and Li, Jiale and Dong, Yuxiao and Tang, Jie and Jie, Wen},
title = {LongBench: A Bilingual Benchmark for Long Context Understanding},
journal = {arXiv preprint arXiv:2308.14508},
year = {2023}
}

@inproceedings{zhou2023context,
author = {Zhou, Wenxuan and Zhang, Sheng and Poon, Hoifung and Chen, Muhao},
title = {Context-Faithful Prompting for Large Language Models},
booktitle = {Findings of the Association for Computational Linguistics: EMNLP 2023},
pages = {14544--14556},
year = {2023},
publisher = {Association for Computational Linguistics},
doi = {10.18653/v1/2023.findings-emnlp.972}

```
@article{gao2023retrieval,
  author  = {Gao, Yunfan and Xiong, Yun and Gao, Xinyu and Jia, Kangxiang and Pan, Jinliu and Bi, Yuxi and Dai, Yi and Sun, Jiawei and Wang, Meng and Wang, Haofen},
  title   = {Retrieval-Augmented Generation for Large Language Models: A Survey},
  journal = {arXiv preprint arXiv:2312.10997},
  year    = {2023}
}

@article{wu2023autogen,
  author  = {Wu, Qingyun and Bansal, Gagan and Zhang, Jie and Wu, Yiran and Li, Beibin and Zhu, Erkang and Gao, Li and Ma, Xiaoyun and Zhang, Chaoyun and Wang, Chi},
  title   = {AutoGen: Enabling Next-Gen LLM Applications via Multi-Agent Conversation},
  journal = {arXiv preprint arXiv:2308.08155},
  year    = {2023}
}

@inproceedings{hong2024metagpt,
  author  = {Hong, Sirui and Zheng, Xiawu and Chen, Jonathan and Cheng, Yuheng and Zhang, Ceyao and Wang, Jinlin and Yau, C. D. and Lin, Zili and Zhou, Liyang and Ran, Chenyu and Xiao, Ling and Wu, Chenglin},
  title   = {MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework},
  booktitle = {International Conference on Learning Representations (ICLR)},
  year    = {2024}
}

@article{mialon2023augmented,
  author  = {Mialon, Gr{\'e}goire and Dess{\`i}, Roberto and Lomeli, Maria and Nalmpantis, Christoforos and Pasunuru, Ram and Raileanu, Roberta and Rozi{\`e}re, Baptiste and Schick, Timo and Dwivedi-Yu, Jane and Celikyilmaz, Asli and Grave, Edouard and Westwood, Yann and Scialom, Thomas},
  title   = {Augmented Language Models: a Survey},
  journal = {arXiv preprint arXiv:2302.07842},
  year    = {2023}
}

@article{sun2023chatgpt,
  author  = {Sun, Weiwei and Yan, Lingyong and Chen, Xinyu and Wang, Shuaiqiang and Zhu, Haoxiang and Ren, Pengjie and Chen, Zhumin and Ren, Zhaochun and de Rijke, Maarten},
  title   = {Is ChatGPT a Good Ranker? Numerical Insights on Pairwise Reranking},
  journal = {arXiv preprint arXiv:2304.09542},
  year    = {2023}
}
```

```
@inproceedings{azaria2023internal,
  author    = {Azaria, Amos and Mitchell, Tom},
  title     = {The Internal State of an LLM Knows When It's Lying},
  booktitle = {Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)},
  pages     = {967--976},
  year      = {2023}
}

@inproceedings{wang2023selfconsistency,
  author    = {Wang, Xuezhi and Wei, Jason and Schuurmans, Dale and Le, Quoc and Chi, Ed and Narang, Sharan and Chowdhery, Aakanksha and Zhou, Denny},
  title     = {Self-Consistency Improves Chain of Thought Reasoning in Language Models},
  booktitle = {International Conference on Learning Representations (ICLR)},
  year      = {2023}
}

@inproceedings{dahiya2024enterprise,
  author    = {Dahiya, Sanya and Gupta, Sparsh and Kumar, Prateek and Agrawal, Puneet},
  title     = {Enterprise Search in the Era of Large Language Models},
  booktitle = {Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval},
  pages     = {210--219},
  year      = {2024}
}

@inproceedings{borgeaud2022improving,
  author    = {Borgeaud, Sebastian and Mensch, Arthur and Hoffmann, Jordan and Cai, Trevor and Rutherford, Eliza and Millican, Katie and Driessche, George van den and Lespiau, Jean-Baptiste and Damoc, Bogdan and Clark, Aidan and de Las Casas, Diego and Guy, Aurelia and Menick, Jacob and Ring, Roman and Young, Tom and Shrivastava, Anshuman and Huang, Lei and Sheng, Jasmine and Reid, Miko{\l}aj and Aslanides, John and Dehghani, Mostafa and Elsen, Erich and Simonyan, Karen and Vinyals, Oriol and Sifre, Laurent and Sifre, Laurent and Kavukcuoglu, Koray and Sdf, B and Fitch, Phil},
  title     = {Improving Language Models by Retrieving from Trillions of Tokens},
  booktitle = {International Conference on Machine Learning (ICML)},
  pages     = {2206--2240},
  year      = {2022}
}

@inproceedings{guu2020realm,
```

```
  author    = {Guu, Kelvin and Lee, Kenton and Tung, Zora and Pasupat, Panupong and
Chang, Ming-Wei},
  title     = {REALM: Retrieval-Augmented Language Model Pre-training},
  booktitle = {International Conference on Machine Learning (ICML)},
  pages     = {3929--3938},
  year      = {2020}
}

@inproceedings{izacard2021leveraging,
  author    = {Izacard, Gautier and Grave, Edouard},
  title     = {Leveraging Passage Retrieval with Generative Language Models for Open
Domain Question Answering},
  booktitle = {Proceedings of the 16th Conference of the European Chapter of the
Association for Computational Linguistics (EACL)},
  pages     = {874--880},
  year      = {2021}
}

@article{glass2022replug,
  author    = {Glass, Michael and Rossiello, Gaetano and Chowdhury, Md Arafat and Naik,
Nitish and R. M. and Sahu, Gaurav and Abdelaziz, Ibrahim and Gliozzo, Alfio},
  title     = {RePlug: Retrieval-Augmented Language Modeling for Inference},
  journal   = {arXiv preprint arXiv:2301.12652},
  year      = {2022}
}

@inproceedings{jiang2023active,
  author    = {Jiang, Zhengbao and Xu, Frank F. and Gao, Luyu and Sun, Zhiqing and Liu, Qian
and Dwyer, Jane and Chen, Chenyan and Zhang, Yue and Neubig, Graham},
  title     = {Active Retrieval Augmented Generation},
  booktitle = {Proceedings of the 2023 Conference on Empirical Methods in Natural
Language Processing (EMNLP)},
  pages     = {7969--7981},
  year      = {2023}
}

@inproceedings{devlin2019bert,
  author    = {Devlin, Jacob and Chang, Ming-Wei and Lee, Kenton and Toutanova, Kristina},
  title     = {BERT: Pre-training of Deep Bidirectional Transformers for Language
Understanding},
  booktitle = {Proceedings of NAACL-HLT 2019},
  pages     = {4171--4186},
  year      = {2019}
```

```
@inproceedings{reimers2019sentencebert,
  author    = {Reimers, Nils and Gurevych, Iryna},
  title     = {Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks},
  booktitle = {Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)},
  pages     = {3982--3988},
  year      = {2019}
}

@article{robertson2009probabilistic,
  author    = {Robertson, Stephen and Zaragoza, Hugo},
  title     = {The Probabilistic Relevance Framework: BM25 and Beyond},
  journal   = {Foundations and Trends in Information Retrieval},
  volume    = {3},
  number    = {4},
  pages     = {333--389},
  year      = {2009}
}

@inproceedings{karpukhin2020dense,
  author    = {Karpukhin, Vladimir and Oguz, Barlas and Min, Sewon and Lewis, Patrick and Wu, Ledell and Edunov, Sergey and Chen, Danqi and Yih, Wen-tau},
  title     = {Dense Passage Retrieval for Open-Domain Question Answering},
  booktitle = {Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)},
  pages     = {6769--6781},
  year      = {2020}
}

@inproceedings{vaswani2017attention,
  author    = {Vaswani, Ashish and Shazeer, Noam and Parmar, Niki and Uszkoreit, Jakob and Jones, Llion and Gomez, Aidan N. and Kaiser, {\L}ukasz and Polosukhin, Illia},
  title     = {Attention Is All You Need},
  booktitle = {Advances in Neural Information Processing Systems (NeurIPS)},
  volume    = {30},
  pages     = {5998--6008},
  year      = {2017}
}

@article{touvron2023llama,
  author    = {Touvron, Hugo and Martin, Louis and Stone, Kevin and Albert, Peter and
```

Almahairi, Amjad and Babaei, Yasmine and Bashlykov, Nikolay and Batra, Soumya and Bhargava, Prajjwal and Bhosale, Shruti and Bikel, Dan and Blecher, Lukas and Ferrer, Cristian Canton and Chen, Moya and Cucurull, Guillem and Esiobu, David and Fernandes, Jude and Fu, Jeremy and Fu, Wenyin and Fuller, Brian and Gao, Cynthia and Goswami, Vedanuj and Goyal, Naman and Hartshorn, Anthony and Hosseini, Saghar and Hou, Rui and Inan, Hakan and Kardas, Marcin and Kerkez, Viktor and Khabsa, Madian and Kloumann, Isabel and Korenev, Arseniy and Koura, Punit Singh and Lachaux, Marie-Anne and Lavril, Thibaut and Lee, Jenya and Liskovich, Diana and Lu, Yinghai and Mao, Yuning and Martinet, Xavier and Martin, Todor and Mishra, Sharan and Molybog, Igor and Pandey, Yixin and Pillai, Jay and Riach, Igor and Rungta, Gaurav and Sankar, Kalyan and Sharma, Sneha and Shelhamer, Evan and Silva, Jiayu and Sridhar, David and Szilvasy, Laszlo and Thomas, Anthony and Wang, Sean and Wang, Yixin and Xiong, Lu and Xu, Xiang and Yang, Yikai and Zhao, Zining and Zhang, Alice and Zettlemoyer, Luke and Scialom, Thomas},
title = {Llama 2: Open Foundation and Fine-Tuned Chat Models},
journal = {arXiv preprint arXiv:2307.09288},
year = {2023}
}

@article{jiang2024mixtral,
author = {Jiang, Albert Q. and Sablayrolles, Alexandre and Roux, Antoine and Mensch, Arthur and Savary, Blanche and Bamford, Chris and Chaplot, Devendra Singh and de las Casas, Diego and Hanna, Emma and Bressand, Florian and Lengyel, Gianna and Bour, Guillaume and Lample, Guillaume and Lavaud, L{\'e}lio Renard and Saulnier, Lucile and Lachaux, Marie-Anne and Stock, Pierre and Le Scao, Teven and Lavril, Thibaut and Wang, Thomas and Lacroix, Timoth{\'e}e and El Sayed, William},
title = {Mixtral of Experts},
journal = {arXiv preprint arXiv:2401.04088},
year = {2024}
}

@techreport{openai2023gpt4,
author = {{OpenAI}},
title = {GPT-4 Technical Report},
institution = {OpenAI},
year = {2023},
note = {arXiv:2303.08774}
}

@techreport{anthropic2024claude3,
author = {{Anthropic PBC}},
title = {The Claude 3 Model Family: Opus, Sonnet, Haiku},
institution = {Anthropic},
year = {2024}

```
@techreport{google2024gemini,
  author      = {{Google Gemini Team}},
  title       = {Gemini 1.5: Unlocking multimodal understanding across millions of tokens},
  institution = {Google DeepMind},
  year        = {2024}
}

@inproceedings{xiong2021ance,
  author    = {Xiong, Lee and Dai, Zhuyun and Chen, Liang Wang and Liu, Zhenghao and Liu,
Zhiyuan and Tie-Yan, Liu},
  title     = {Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text
Retrieval},
  booktitle = {International Conference on Learning Representations (ICLR)},
  year      = {2021}
}

@inproceedings{gao2021simcse,
  author    = {Gao, Tianyu and Yao, Xingcheng and Chen, Danqi},
  title     = {SimCSE: Simple Contrastive Learning of Sentence Embeddings},
  booktitle = {Proceedings of the 2021 Conference on Empirical Methods in Natural
Language Processing (EMNLP)},
  pages     = {6894--6910},
  year      = {2021}
}

@article{su2024roformer,
  author    = {Su, Jianlin and Ahmed, Murtadha and Lu, Yu and Pan, Shengfeng and Bo, Wen
and Liu, Yunfeng},
  title     = {RoFormer: Enhanced Transformer with Rotary Position Embedding},
  journal   = {Neurocomputing},
  volume    = {568},
  pages     = {127063},
  year      = {2024},
  doi       = {10.1016/j.neucom.2023.127063}
}

@inproceedings{chen2023longlora,
  author    = {Chen, Yukang and Qian, Shengju and Tang, Haotian and Lai, Xin and Liu, Zhijian
and Han, Song and Jia, Jiaya},
  title     = {LongLoRA: Efficient Fine-tuning of Long-Context Large Language Models},
  booktitle = {International Conference on Learning Representations (ICLR)},
```

```
  year      = {2024}
}

@article{xiao2023streamingllm,
  author    = {Xiao, Guangxuan and Tian, Yuandong and Chen, Beidi and Han, Song and
Lewis, Mike},
  title     = {Efficient Streaming Language Models with Attention Sinks},
  journal   = {arXiv preprint arXiv:2309.17453},
  year      = {2023}
}

@article{ji2023survey,
  author    = {Ji, Ziwei and Lee, Nayeon and Frieske, Rita and Yu, Tiezheng and Su, Dan and
Xu, Yan and Ishii, Etsuko and Yeung, Yejin and Del Tredici, Marco and Xu, Peng and Fung,
Pascale},
  title     = {Survey of Hallucination in Natural Language Generation},
  journal   = {ACM Computing Surveys},
  volume    = {55},
  number    = {12},
  pages     = {1--38},
  year      = {2023}
  doi       = {10.1145/3571730}
}

@inproceedings{min2023factscore,
  author    = {Min, Sewon and Kalai, Adam Tauman and Groeneveld, Dirk and Suchanek,
Fabian and Hajishirzi, Hannaneh},
  title     = {FActScore: Fine-grained Atomic Evaluation of Factual Precision in Atomically
Verifiable Text Generation},
  booktitle = {Proceedings of the 2023 Conference on Empirical Methods in Natural
Language Processing (EMNLP)},
  pages     = {12076--12099}
  year      = {2023}
}

@manual{microsoft2024copilot,
  title     = {Microsoft Copilot Studio & Dynamics 365 Customer Service AI Architecture},
  author    = {{Microsoft Corporation}},
  year      = {2024},
  url       = {https://learn.microsoft.com/en-us/copilot/studio/}
}

@manual{google2024agentassist,
```

```
title     = {Google Cloud Agent Assist & Vertex AI Search Documentation}
author    = {{Google LLC}}
year      = {2024}
url       = {https://cloud.google.com/agent-assist/docs}
```

```
@manual{salesforce2024agentforce,
title     = {Salesforce Agentforce Platform & Service Cloud Architecture},
author    = {{Salesforce Inc.}},
year      = {2024},
url       = {https://www.salesforce.com/agentforce/}
```

```
@manual{zendesk2024ai,
title     = {Zendesk AI Architecture & Agent Workspace Integration},
author    = {{Zendesk Inc.}},
year      = {2024},
url       = {https://www.zendesk.com/service/ai/}
```

```
@manual{aws2024amazonconnect,
title     = {Amazon Connect Wisdom & Amazon Q Business Developer Guide},
author    = {{Amazon Web Services Inc.}},
year      = {2024},
url       = {https://docs.aws.amazon.com/connect/}
```

```
@inproceedings{padaki2020rethinking,
author    = {Padaki, Ramith and Dai, Zhuyun and Callan, Jamie},
title     = {Rethinking Query Expansion for BERT Reranking},
booktitle = {Advances in Information Retrieval: 42nd European Conference on IR
Research (ECIR 2020)},
pages     = {297--304},
year      = {2020},
publisher = {Springer},
doi       = {10.1007/978-3-030-45442-5_37}
```

```
@article{dhuliawala2023cove,
author    = {Dhuliawala, Shehzaad and Komeili, Mojtaba and Xu, Jing and Raileanu, Roberta
and Li, Xian and Celikyilmaz, Asli and Weston, Jason},
title     = {Chain-of-Verification Reduces Hallucinations in Large Language Models},
journal   = {arXiv preprint arXiv:2309.11495},
```

year = {2023}

Análisis Crítico, Vacíos de Investigación y Recomendaciones de Diseño

Tendencias Tecnológicas Predominantes

La revisión sistemática del estado del arte evidencia la consolidación de patrones clave para la construcción de copilotos conversacionales en tiempo real:

1. **Convergencia Híbrida de Recuperación (Dense + Sparse + Reranking):** La literatura confirma que la búsqueda basada en vectores continuos (embeddings densos) es insuficiente por sí sola para lidiar con el vocabulario técnico corporativo[10]. El patrón dominante combina una primera fase de recuperación híbrida (SPLADE o BM25 junto con embeddings BGE M3 o E5) agregada mediante Reciprocal Rank Fusion (RRF), seguida de una reordenación mediante Cross-Encoders[10].
2. **Evolución hacia RAG Agentico y Basado en Grafos:** La transición de arquitecturas lineales a flujos donde el copiloto evalúa dinámicamente si requiere consultar fuentes externas (Self-RAG), verifica la veracidad de la búsqueda (CRAG) o analiza relaciones relacionales complejas entre políticas y procedimientos (GraphRAG)[10].
3. **Estandarización de Interfaces con MCP:** La integración de herramientas y fuentes de conocimiento mediante el Model Context Protocol (MCP) se consolida como la solución al problema de la fragmentación de integraciones propietarias[10].
4. **Evaluación Automatizada y Continua (RAGAS):** El despliegue empresarial demanda la verificación continua del desempeño del RAG utilizando métricas desacopladas (*Faithfulness*, *Context Precision*) mediante jueces sintéticos (*LLM-as-a-Judge*)[3].

Problemas Abiertos y Vacíos en la Literatura

Se identifican tres brechas no resueltas en la literatura actual que constituyen oportunidades directas de contribución para la tesis:

1. **Tensión entre Latencia en Tiempo Real y Razonamiento Agentico Multi-Paso:** Las arquitecturas de agentes que incorporan autocrítica (Reflexion) o expansión de grafos (GraphRAG) introducen latencias elevadas que exceden las restricciones de interacción por chat en vivo[12]. Existe un vacío en la optimización de estas canalizaciones para mantener tiempos de respuesta inferiores a los 1,200 milisegundos sin perder rigurosidad.
2. **Sincronización Dinámica del Estado UI-Operador:** Los sistemas Agent Assist actuales analizan el texto del chat, pero permanecen aislados de las acciones que el operador ejecuta en la interfaz gráfica del CRM. Un área abierta reside en la fusión del contexto conversacional con los eventos de la interfaz de usuario (*UI Event Context*).
3. **Gestión de Ruido en Conversaciones Multitema e Interrumpidas:** La degradación del rendimiento de los modelos en ventanas de contexto extenso cuando la consulta del

usuario cambia de tema o se reanuda tras largos periodos de inactividad sigue siendo un desafío operativo.

Justificación de las Referencias Clave para la Tesis

La elección del corpus de Nivel 1 fundamenta cada uno de los capítulos de la tesis:

- Brynjolfsson et al. (2025)[1]: Proporciona la justificación socioeconómica del proyecto, demostrando que un copiloto HITL incrementa la productividad en un 14%-15% y reduce la brecha de experiencia[1].
- Lewis et al. (2020)[6]: Fundamenta la arquitectura teórica de la Generación Aumentada por Recuperación[6].
- Edge et al. (2024)[12]: Ofrece el método para estructurar manuales y políticas de soporte jerárquicas mediante GraphRAG[10].
- Shinn et al. (2023)[13]: Proporciona la estrategia de autocorrección lingüística (Reflexion) para gestionar llamadas a herramientas empresariales[13].
- Shahul ES et al. (2024)[21]: Aporta el marco cuantitativo de evaluación para validar experimentalmente las hipótesis del trabajo de grado[21].
- Formal et al. (2021)[10] y Nogueira & Cho (2019)[15]: Fundamentan la construcción del motor de búsqueda híbrida y *reranking* en la capa de datos[10].
- **Especificación MCP (2024):** Sustenta la arquitectura software de comunicación multisistema e interoperabilidad corporativa.

Recomendaciones de Diseño Arquitectónico para el Copiloto

Con el propósito de orientar la implementación práctica del prototipo del copiloto en la tesis de Ingeniería Informática, se proponen las siguientes directrices de diseño:

1. **Adopción de un Pipeline de Recuperación Híbrido de Dos Etapas:** Implementar una etapa de recuperación primaria que combine la búsqueda dispersa mediante SPLADE (o BM25 adaptado) y la búsqueda densa utilizando embeddings BGE-M3 o E5, fusionando las puntuaciones mediante el algoritmo Reciprocal Rank Fusion (RRF)[10]. Incorporar una segunda etapa de refinamiento basada en un Cross-Encoder para reordenar los pasajes candidatos antes de introducirlos en la ventana de contexto[15].
2. **Despliegue de Servidores MCP Modulares:** Separar la lógica de negocio y las integraciones de datos en servidores MCP independientes. Diseñar un servidor MCP de Recursos encargado de abstraer la base de conocimientos documental y un servidor MCP de Herramientas orientado a ejecutar las consultas de estado en el CRM o ERP.
3. **Filtro de Factualidad con Inferencia de Lenguaje Natural (NLI):** Integrar un módulo de evaluación pre-despliegue que verifique la implicación lógica de cada afirmación generada por el LLM contra los pasajes recuperados[20]. Las sugerencias cuya puntuación de veracidad (*Faithfulness*) se ubique por debajo de un umbral aceptable (ej. < 0.85 en RAGAS) deben ser marcadas con una advertencia visual para el operador[3].
4. **Diseño de Interfaz HITL de Baja Carga Cognitiva:** La consola del operador debe estructurarse mediante paneles no intrusivos que desplieguen tres componentes clave: la respuesta textual sugerida con botones de edición rápida, botones de acción de un

solo clic para la ejecución de herramientas validadas y fragmentos de citas textuales que permitan auditar el origen de la información en la documentación corporativa[9].

5. **Búfer de Memoria Episódica para Correcciones:** Capturar las ediciones que el operador realiza sobre las sugerencias del modelo e ingresarlas a un búfer de memoria episódica. Este registro de interacción se utilizará como retroalimentación lingüística para refinar los prompts del copiloto y alimentar futuros procesos de entrenamiento[13].

Obras citadas

1. Generative AI at Work Erik Brynjolfsson, Danielle Li, and Lindsey R. Raymond - NBER, https://www.nber.org/system/files/working_papers/w31161/revisions/w31161.rev1.pdf
2. arXiv:2304.11771v2 [econ.GN] 6 Nov 2024, https://arxiv.org/pdf/2304.11771
3. RAGAs: Automated Evaluation of Retrieval Augmented Generation | Request PDF, https://www.researchgate.net/publication/393020278_RAGAs_Automated_Evaluation_of_Retrieval_Augmented_Generation
4. NBER WORKING PAPER SERIES GENERATIVE AI AT WORK Erik Brynjolfsson Danielle Li Lindsey R. Raymond Working Paper 31161 http://www., https://www.nber.org/system/files/working_papers/w31161/revisions/w31161.rev0.pdf
5. Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers - arXiv, https://arxiv.org/html/2506.00054v1
6. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks - ResearchGate, https://www.researchgate.net/publication/341639856_Retrieval-Augmented_Generation_for_Knowledge-Intensive_NLP_Tasks
7. GENERATIVE AI AT WORK˚ - CIRJE Center for International Research on the Japanese Economy, https://www.cirje.e.u-tokyo.ac.jp/research/workshops/emf/paper2024/emf1209.pdf
8. (PDF) A Modular Benchmarking Framework for Evaluating LLM-Based Agent Applications, https://www.researchgate.net/publication/399529200_A_Modular_Benchmarking_Framework_for_Evaluating_LLM-Based_Agent_Applications
9. [PDF] RAGAs: Automated Evaluation of Retrieval Augmented Generation - Semantic Scholar, https://www.semanticscholar.org/paper/RAGAs%3A-Automated-Evaluation-of-Retrieval-Augmented-Shahul-James/f5e9e5bbe22f0263be1f1ce88c66978a2b927772
10. When Search Engine Services Meet Large Language Models: Visions and Challenges, https://www.computer.org/csdl/journal/sc/2024/06/10654534/1ZMv8kfiTUQ
11. Rethinking Query Expansion for BERT Reranking - PMC,

https://pmc.ncbi.nlm.nih.gov/articles/PMC7148061/
12. From Local to Global: A Graph RAG Approach to Query-Focused Summarization, https://movingpixel.net/Notes/Papers/edgeLocalGlobalGraph2024
13. [PDF] Reflexion: language agents with verbal reinforcement learning - Semantic Scholar, https://www.semanticscholar.org/paper/Reflexion%3A-language-agents-with-verbal-learning-Shinn-Cassano/0671fd553dd670a4e820553a974bc48040ba0819
14. Reflexion: language agents with verbal reinforcement learning - OpenReview, https://openreview.net/forum?id=vAElhFcKW6
15. Passage Re-ranking with BERT - BibSonomy, https://www.bibsonomy.org/bibtex/24390448f16b5b1b8f33fb67ac4c7b4c3/festplatte
16. A Passage Retrieval Transformer-based Re-ranking Model for Truthful Consumer Health Search - AWS, https://ecmlpkdd-storage.s3.eu-central-1.amazonaws.com/preprints/2023/research/lncs14169346.pdf
17. [1901.04085] Passage Re-ranking with BERT - arXiv, https://arxiv.org/abs/1901.04085
18. How AI Agents Really Work: Beyond the Hype, Inside the Architecture | by Gianluca Mondillo, https://medium.com/@gianluca.mondillo/how-ai-agents-really-work-beyond-the-hype-inside-the-architecture-aa6c892a5c2a
19. Reflexion: language agents with verbal reinforcement learning, https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html
20. RAGAS: Automated Evaluation of Retrieval Augmented Generation - ACL Anthology, https://aclanthology.org/2024.eacl-demo.16.pdf
21. [2309.15217] Ragas: Automated Evaluation of Retrieval Augmented Generation - arXiv, https://arxiv.org/abs/2309.15217
22. RAGAs: Automated Evaluation of Retrieval Augmented Generation - ACL Anthology, https://aclanthology.org/2024.eacl-demo.16/
23. source: arxiv:2308.03688 — AgentBench: Evaluating LLMs as, https://huggingface.co/datasets/rl-llm-wiki/knowledge-base/commit/eccd81334dd2d0e3a681c9d73502801c7c273401
24. Erik Brynjolfsson - IDEAS/RePEc, https://ideas.repec.org/e/pbr87.html
25. Generative AI at Work* | The Quarterly Journal of Economics - Oxford Academic, https://academic.oup.com/qje/article/140/2/889/7990658
26. Research - Erik Brynjolfsson, https://www.brynjolfsson.com/research
27. Reflexion: language agents with verbal reinforcement learning - AI Reproducibility Index, https://reproducibilityindex.ai/papers/reflexion_language_agents_with_verbal_reinforcement_learning__126e5960
28. Revisiting Passage Re-Ranking with BERT on MS MARCO - Institute for Computing and Information Sciences, https://www.cs.ru.nl/masters-theses/2020/T_Janssen___Re-ranking_BERT_revisiti

ng_passage_re-ranking_with_BERT_on_MS_MACRO.pdf
29. Reflexion: language agents with verbal reinforcement learning | Request PDF, https://www.researchgate.net/publication/401463998_Reflexion_language_agents_with_verbal_reinforcement_learning
30. [2303.11366] Reflexion: Language Agents with Verbal Reinforcement Learning - arXiv, https://arxiv.org/abs/2303.11366
31. Beyond Traditional Metrics - Evaluating the Generation Stage of RAG Systems, https://deconvoluteai.com/blog/rag/metrics-generation